

T.C
GÜMÜŞHANE ÜNİVERSİTESİ
GÜMÜŞHANE MESLEK YÜKSEKOKULU
BİLGİSAYAR TEKNOLOJİLERİ BÖLÜMÜ
BİLGİSAYAR PROGRAMCILIĞI PROGRAMI



Doğal Dil İşleme Dersi

Final Ödev-2 Raporu

Eğitilen Modellerle Metin Benzerliği

Hesaplama ve Değerlendirme

Proje #33: Endüstriyel Arıza Kodları Eşleştirme

Öğrenci Adı: Rodolfo Mba NDONG MEBAHA

Öğrenci No: 2311081639

Ders: Doğal Dil İşleme

Öğretim Elemanı: Dr. Rabia Yaşa Koştas

Google Drive (Model Dosyaları):
[DRIVE KLASÖRÜ İÇİN TIKLAYAN](#)

İÇİNDEKİLER

1. GİRİŞ	2
1.1. Problemin Tanımı	2
1.2. Kullanılan Veri Seti	2
1.3. Kaynak Kodlar ve Model Dosyaları	3
2. YÖNTEM	3
2.1. Vektörleştirme — Word2Vec Modelleri	3
2.2. Giriş Metni	4
2.3. Cosine Benzerliği Hesaplama Yöntemi	4
3. SONUÇLAR VE DEĞERLENDİRME	5
3.1. Her Model İçin İlk 5 Benzer Metin	5
3.2. Değerlendirme-1: Cosine Benzerlik Tablosu (Objective Evaluation)	5
3.3. Değerlendirme-2: Anlamsal Değerlendirme (Subjective Evaluation)	7
3.4. Değerlendirme-3: Jaccard Sıralama Tutarlılığı	8
3.5 Model Yapılandırmalarının Başarıya Etkisi	9
4. SONUÇ VE ÖNERİLER	10
Genel Çıkarımlar	10
Hangi Model, Hangi Görev İçin Daha Uygun?	10
Gelecek Öneriler	10

1. GİRİŞ

1.1. Problemin Tanımı

Bu ödevin amacı, birinci ödevde ön işleme tabi tutulmuş verilerle eğitilmiş Word2Vec modellerini kullanarak metinler arası benzerlik hesaplamalarını gerçekleştirmek ve kullanılan modellerin karşılaştırmalı başarımını değerlendirmektir.

Bu bağlamda seçilen proje konusu **#33: Endüstriyel Arıza Kodları Eşleştirmektir**. Problemin özü şudur: endüstriyel sistemlerde üretilen hata kodlarının açıklamaları teknik belgelerden derlenmekte ve bir kullanıcının doğal dil ile yazdığı arıza ifadesine en benzer kayıtlar bulunmaktadır.

1.2. Kullanılan Veri Seti

Ham Veri

Veri seti, farklı endüstriyel sistemlere ait Türkçe arıza açıklamalarından oluşmaktadır. Toplam **80 belge** elle derlenmiş olup her belge bir arıza koduna karşılık gelmektedir. Belgeler motor, pompa, kompresör, robot, PLC, ısıtma işlem fırını ve daha pek çok endüstriyel ekipmana ait gerçekçi arıza açıklamalarını içermektedir.

Veri yapısı aşağıdaki gibidir:

Sütun	Açıklama
document_id	doc001'den doc080'e benzersiz kimlik
content	Türkçe arıza açıklaması (1-3 cümle)

Ham Veri ile Ön İşlenmiş Verinin Karşılaştırması

Veri Seti	Kayıt	Ort. Kelime/Belge	Toplam Kelime
Ham Veri	80	21.4	1712
Lemmatized	80	14.2	1134
Stemmed	80	14.2	1139

Stop-word temizleme ve morfolojik indirgeme sayesinde kelime sayısı yaklaşık %34 azalmış; bu sayede modelin daha anlamlı bağlamsal vektörler öğrenmesi sağlanmıştır.

1.3. Kaynak Kodlar ve Model Dosyaları

Tüm kaynak kodlar ve çalıştırma talimatları README dosyasında yer almaktadır. Model dosyaları (boyut nedeniyle) Google Drive’da paylaşılmıştır:

<https://drive.google.com/drive/folders/1pW9pJiBN9Wuxamajx6E9j84Bqti1ThEe?usp=sharing>

2. YÖNTEM

2.1. Vektörleştirme — Word2Vec Modelleri

Gensim kütüphanesi kullanılarak toplamda **16 Word2Vec modeli** eğitilmiştir: 8 adet lemmatized.csv için, 8 adet stemmed.csv için.

Model Parametreleri

#	Model Adı	Tür	Pencere	Boyut
1	lemmatized_cbow_win2_dim100	CBOW	2	100
2	lemmatized_skipgram_win2_dim100	SkipGram	2	100
3	lemmatized_cbow_win4_dim100	CBOW	4	100
4	lemmatized_skipgram_win4_dim100	SkipGram	4	100
5	lemmatized_cbow_win2_dim300	CBOW	2	300
6	lemmatized_skipgram_win2_dim300	SkipGram	2	300
7	lemmatized_cbow_win4_dim300	CBOW	4	300
8	lemmatized_skipgram_win4_dim300	SkipGram	4	300
9	stemmed_cbow_win2_dim100	CBOW	2	100
10	stemmed_skipgram_win2_dim100	SkipGram	2	100
11	stemmed_cbow_win4_dim100	CBOW	4	100
12	stemmed_skipgram_win4_dim100	SkipGram	4	100
13	stemmed_cbow_win2_dim300	CBOW	2	300
14	stemmed_skipgram_win2_dim300	SkipGram	2	300
15	stemmed_cbow_win4_dim300	CBOW	4	300
16	stemmed_skipgram_win4_dim300	SkipGram	4	300

Tablo 1: Eğitilen 16 Word2Vec modeli

Tüm modeller min_count=1, epochs=100, seed=42 parametreleriyle eğitilmiştir. Lemmatized corpus kelime hazinesi 462, Stemmed corpus ise 550 kelimeden oluşmaktadır.

2.2. Giriş Metni

Görev-2 gereksinimlerine uygun olarak giriş metni **veri setinin içinden** seçilmiştir:

Belge ID: doc001

Ham metin: Motor aşırı ısınma hatası tespit edildi. Soğutma sistemi yetersiz çalışıyor ve fan devreye girmiyor. Termostat değeri limitin üzerinde seyrediyor.

Lemmatized: motor aşırı ısınmak hata tespit etmek soğutmak sistem yeter çalışmak fan devre girmek termostat değeri limit üzeri seyretmek

Stemmed: motor aşırı ısınma hatası tespit edil soğutma sistemi yetersiz çalışıyor fan devreye girmiyor termostat değeri limit üzeri seyrediyor.

2.3. Cosine Benzerliği Hesaplama Yöntemi

Her belge için Word2Vec vektörleri şu şekilde hesaplanmaktadır:

1. Metin tokenize edilir.
2. Her token için modelden vektör alınır (modelde olmayan tokenler atlanır).
3. Tüm vektörlerin aritmetik ortalaması alınır → belge vektörü.
4. Hiçbir token modelde yoksa **sıfır vektör** atanır (savunma mekanizması).
5. Giriş metni ile her belge arasında kosinüs benzerliği hesaplanır.

$$\cos(\theta) = \frac{\vec{q} \cdot \vec{d}}{|\vec{q}| |\vec{d}|}$$

3. SONUÇLAR VE DEĞERLENDİRME

3.1. Her Model İçin İlk 5 Benzer Metin

Aşağıda seçili modeller için en benzer 5 belge verilmiştir. Tam liste (tüm 16 model) notebooks/03_benzerlik_hesaplama.py çıktısında yer almaktadır.

lemmatized_skipgram_win2_dim300 (En Başarılı Model)

Sıra	Belge	Cosine Skoru	İçerik (kısaltılmış)
1	doc031	0.9972	Elektrik panosu aşırı ısı alarmı...
2	doc025	0.9971	Endüksiyon ocağı güç modülü hatası...
3	doc056	0.9948	Soğuk şekillendirme pres yağ sıcaklık...
4	doc069	0.9946	Manyetik separatör güç kaynağı arızası...
5	doc078	0.9944	Çift vidalı ekstrüder melting zone...

stemmed_skipgram_win4_dim100 (En Başarısız Model)

Sıra	Belge	Cosine Skoru	İçerik (kısaltılmış)
1	doc025	0.9013	Endüksiyon ocağı güç modülü hatası...
2	doc031	0.8999	Elektrik panosu aşırı ısı alarmı...
3	doc013	0.8685	Soğutma kulesi fan motoru arızası...
4	doc056	0.8672	Soğuk şekillendirme pres yağ sıcaklık...
5	doc026	0.8671	Robot kol eklem hareket sınırı aşıldı...

3.2. Değerlendirme-1: Cosine Benzerlik Tablosu (Objective Evaluation)

Model Adı	Top-5 Cosine Skorları	Ortalama
lemmatized_cbow_win2_dim100	[0.9998, 0.9998, 0.9997, 0.9996, 0.9996]	0.9997
lemmatized_cbow_win2_dim300	[0.9999, 0.9999, 0.9999, 0.9999, 0.9999]	0.9999
lemmatized_cbow_win4_dim100	[0.9997, 0.9997, 0.9995, 0.9994, 0.9994]	0.9995

Model Adı	Top-5 Cosine Skorları	Ortalama
lemmatized_cbow_win4_dim300	[0.9999, 0.9999, 0.9998, 0.9998, 0.9998]	0.9999
lemmatized_skipgram_win2_dim100	[0.9933, 0.9913, 0.9869, 0.9835, 0.9825]	0.9875
lemmatized_skipgram_win2_dim300	[0.9972, 0.9971, 0.9948, 0.9946, 0.9944]	0.9956
lemmatized_skipgram_win4_dim100	[0.9509, 0.9348, 0.8775, 0.8578, 0.8462]	0.8934
lemmatized_skipgram_win4_dim300	[0.9627, 0.9600, 0.9089, 0.9020, 0.8851]	0.9237
stemmed_cbow_win2_dim100	[0.9998, 0.9998, 0.9997, 0.9997, 0.9997]	0.9997
stemmed_cbow_win2_dim300	[0.9999, 0.9999, 0.9999, 0.9999, 0.9999]	0.9999
stemmed_cbow_win4_dim100	[0.9997, 0.9997, 0.9996, 0.9996, 0.9996]	0.9996
stemmed_cbow_win4_dim300	[0.9999, 0.9999, 0.9999, 0.9999, 0.9999]	0.9999
stemmed_skipgram_win2_dim100	[0.9931, 0.9928, 0.9911, 0.9895, 0.9895]	0.9912
stemmed_skipgram_win2_dim300	[0.9974, 0.9973, 0.9967, 0.9967, 0.9966]	0.9970
stemmed_skipgram_win4_dim100	[0.9013, 0.8999, 0.8685, 0.8672, 0.8671]	0.8808
stemmed_skipgram_win4_dim300	[0.9419, 0.9357, 0.9309, 0.9155, 0.9139]	0.9276

Tablo 2: 16 model için cosine benzerlik tablosu

3.3. Değerlendirme-2: Anlamsal Değerlendirme (Subjective Evaluation)

Her modelin önerdiği 5 belge için 1–5 arası anlamsal benzerlik puanı verilmiştir. Bu puanlama yapay zekâ kullanılmadan, insan değerlendirmesiyle yapılmıştır

Puanlama Kriteri:

- **1 puan:** Çok alakasız, anlamca zayıf benzerlik
- **2 puan:** Kısmen ilgili ama bağlamı tutmuyor
- **3 puan:** Ortalama düzeyde benzer
- **4 puan:** Anlamlı, açık benzerlik içeriyor

Model Adı	Anlamsal Puanlar	Ortalama
lemmatized_cbow_win2_dim100	[5, 4, 4, 3, 3]	3.80
lemmatized_skipgram_win2_dim100	[5, 4, 4, 3, 3]	3.80
lemmatized_cbow_win4_dim100	[5, 4, 4, 4, 3]	4.00
lemmatized_skipgram_win4_dim100	[5, 4, 4, 4, 3]	4.00
lemmatized_cbow_win2_dim300	[5, 4, 4, 3, 3]	3.80
lemmatized_skipgram_win2_dim300	[5, 5, 4, 4, 3]	4.20
lemmatized_cbow_win4_dim300	[5, 4, 4, 4, 3]	4.00
lemmatized_skipgram_win4_dim300	[5, 5, 4, 4, 3]	4.20
stemmed_cbow_win2_dim100	[5, 4, 3, 3, 2]	3.40
stemmed_skipgram_win2_dim100	[5, 4, 3, 3, 2]	3.40
stemmed_cbow_win4_dim100	[5, 4, 3, 3, 3]	3.60
stemmed_skipgram_win4_dim100	[5, 4, 4, 3, 3]	3.80
stemmed_cbow_win2_dim300	[5, 4, 3, 3, 2]	3.40
stemmed_skipgram_win2_dim300	[5, 4, 4, 3, 3]	3.80
stemmed_cbow_win4_dim300	[5, 4, 4, 3, 3]	3.80
stemmed_skipgram_win4_dim300	[5, 4, 4, 4, 3]	4.00


Tablo 3: Anlamsal değerlendirme tablosu (insan puanlaması)

Yorum: En yüksek anlamsal skoru lemmatized_skipgram_win2_dim300 ve lemmatized_skipgram_win4_dim300 modelleri almıştır (ortalama 4.20/5.0). SkipGram mimarisi, nadir kelimeleri CBOW’a kıyasla daha iyi öğrenmekte; dim=300 ise daha zengin bağlamsal temsiller üretmektedir. Stemmed modellerin anlamsal skorunun daha düşük olması, Snowball stemmer’ın Türkçe morfolojisini Zeyrek kadar başarılı işleyememesinden kaynaklanmaktadır.

3.4. Değerlendirme-3: Jaccard Sıralama Tutarlılığı

İki modelin aynı giriş metnine verdiği top-5 sonuç kümesi arasındaki örtüşme Jaccard benzerliği ile ölçülmüştür:

$$J(A,B)=\frac{|A\cap B|}{|A\cup B|}$$



Şekil 1: 16×16 Jaccard Benzerlik Matrisi — Model Sıralama Örtüşmesi

Öne Çıkan Bulgular:

- lemmatized_cbow_win4_dim100 ve lemmatized_skipgram_win2_dim100 arasında Jaccard = 1.0 gözlemlenmiştir; bu iki model birebir aynı belgeleri önermiştir.
- stemmed_cbow_win2, stemmed_cbow_win4 ve stemmed_skipgram_win2_dim100 modelleri de kendi aralarında Jaccard = 1.0 ile çok yüksek örtüşme göstermiştir.
- En düşük örtüşme (Jaccard = 0.25), farklı ön işleme türü ve farklı vektör boyutu kullanan modeller arasında görülmüştür.
- **Genel bulgu:** Aynı mimariye (CBOW-CBOW veya SG-SG) sahip modeller benzer belge kümesi önerme eğilimindedir; ön işleme türü (lemmatized/stemmed) ise modelin sonuç setini daha belirgin şekilde farklılaştırmaktadır.

3.5 Model Yapılandırmalarının Başarıya Etkisi

- **CBOW vs SkipGram:** CBOW cosine benzerliği açısından daha yüksek skor alırken, SkipGram anlamsal değerlendirmede üstün gelmiştir. Bu durum, CBOW'un ortalama vektör hesaplamasında daha "sıkışık" temsiller üretmesinden; SkipGram'ın ise bireysel kelime bağlamını daha iyi modellemesinden kaynaklanmaktadır.
- **Pencere Boyutu:** window=4, teknik belgeler için daha geniş bağlamı yakalamakta, özellikle anlamsal değerlendirmede window=2'ye kıyasla 0.2 puanlık artış sağlamaktadır.
- **Vektör Boyutu:** dim=300, dim=100'e göre hem cosine hem anlamsal değerlendirmede tutarlı biçimde daha başarılıdır. Küçük corpus'larda dahi ek kapasite model kalitesini artırmıştır.

Lemmatized vs Stemmed: Zeyrek ile yapılan lemmatizasyon, Türkçe morfolojisini daha doğru işlediğinden lemmatized modeller stemmed modellerine kıyasla ortalama 0.4 puan daha yüksek anlamsal skor almıştır.

4. SONUÇ VE ÖNERİLER

Bu çalışmada, endüstriyel arıza kodlarını doğal dil ifadeleriyle eşleştiren bir sistem geliştirilmiştir. 80 Türkçe arıza açıklamasından oluşan özgün bir veri seti oluşturulmuş; Zeyrek lemmatizasyon ve Snowball stemming ile ön işlemden geçirilen bu veri üzerinde 16 farklı Word2Vec modeli eğitilmiştir.

Genel Çıkarımlar

- **En başarılı model:** lemmatized_skipgram_win2_dim300 — anlamsal ortalama 4.20/5.0, cosine ortalama 0.9956. SkipGram mimarisi, Türkçe teknik belgeler için daha uygun bağlamsal temsiller üretmektedir.
- **En tutarsız model:** stemmed_skipgram_win4_dim100 — geniş pencere ve düşük boyut kombinasyonu, az sayıda belgeden oluşan corpus'ta aşırı genellemeye yol açmıştır.

Ön işleme kalitesi belirleyicidir: Türkçe gibi zengin morfolojili dillerde lemmatizasyon, stemming'e kıyasla belirgin biçimde üstün sonuçlar vermektedir.

Hangi Model, Hangi Görev İçin Daha Uygun?

Görev Türü	Önerilen Model
Hızlı prototipleme (düşük kaynak)	lemmatized_cbow_win2_dim100
En yüksek anlamsal doğruluk	lemmatized_skipgram_win2_dim300
Cosine tabanlı sıralama sistemi	stemmed_cbow_win2_dim300
Geniş bağlam gerektiren eşleştirme	lemmatized_skipgram_win4_dim300

Gelecek Öneriler

1. Veri seti 80 belgeden daha büyük bir corpus'a (500+) genişletilerek model kalitesi artırılabilir.
2. BERT tabanlı Türkçe modeller (BERTurk) kullanılarak daha güçlü bağlamsal temsiller elde edilebilir.
3. TF-IDF ağırlıklı vektör ortalaması ile saf aritmetik ortalama karşılaştırılabilir.

4. Streamlit arayüzü gerçek zamanlı model seçimi ve birden fazla giriş metni desteğiyle genişletilebilir.